

Entrepôt de Données de Santé (EDS)

Cas métier — Centre Hospitalier Universitaire (CHU)

Projet fil rouge de la semaine

Données fournies : source-filestorage/

Livrables : Partie 1 + Partie 2

1 Contexte

Le **CHU** souhaite se doter d'un **Entrepôt de Données de Santé (EDS)**. Ses données sont aujourd'hui éparpillées dans plusieurs systèmes (dossier patient, urgences, laboratoire, monitoring des chambres) et exportées **chaque jour** sous forme de fichiers, dans des formats différents. La direction veut en tirer deux usages : **le pilotage hospitalier** et **la recherche clinique**.

⚠ Données de santé — catégorie particulière (RGPD, art. 9)

La conformité n'est pas une option : c'est une **contrainte de conception** présente à chaque étape de votre chaîne de traitement.

2 Votre mission

1

Récupérer

Automatiser la collecte des fichiers déposés chaque jour.

2

Fiabiliser

Structurer des données hétérogènes en informations exploitables.

3

Restituer

Produire des indicateurs via des dashboards.

4

Automatiser

Rejouer le traitement seul, de façon fiable et tracée.

3 Les données fournies

Le CHU **dépose chaque jour** ses fichiers dans un espace de stockage (le *filestorage*). Vous disposez de **plusieurs jours** de dépôt. Les formats sont **volontairement mélangés** — c'est la réalité d'un hôpital.

```
source-filestorage/ |— patients/<AAAA-MM-JJ>/patients.csv CSV |— sejours/<AAAA-MM-JJ>/sejours.csv CSV |—
diagnostics/<AAAA-MM-JJ>/diagnostics.json JSON |— monitoring/<AAAA-MM-JJ>/monitoring.parquet Parquet · volumineux |—
referentiels/<AAAA-MM-JJ>/{services,cim10}.csv CSV
```

Accès en lecture seule

Vous ne pouvez que **lire** ce que le CHU dépose. À vous de recopier ces fichiers vers votre propre zone de travail avant de les traiter.

Dictionnaire de données

patients.csv

CSV

⚠ Contient l'identité RÉELLE des patients

COLONNE	TYPE	DESCRIPTION
patient_id	texte	IPP — identifiant interne (en clair). Clé de jointure avec sejours
nir	texte	⚠ N° sécurité sociale — directement identifiant
nom	texte	⚠ Nom — directement identifiant
prenom	texte	⚠ Prénom — directement identifiant
birth_date	date	Date de naissance complète
sex	texte	Sexe (M / F)
region_code	texte	Département de résidence

Ces identifiants ne doivent **jamais** entrer dans l'entrepôt : à anonymiser dès l'entrée du lake (cf. § 5 et § 7).

sejours.csv

CSV

Un séjour = un passage à l'hôpital

COLONNE	TYPE	DESCRIPTION
stay_id	texte	Identifiant du séjour
patient_id	texte	Référence au patient
service_code	texte	Service d'hospitalisation (cf. référentiel)
admission_ts	horodatage	Date/heure d'admission
discharge_ts	horodatage	Date/heure de sortie — peut être vide (séjour en cours)
admission_mode	texte	urgence, programme, mutation
discharge_mode	texte	domicile, mutation, transfert, deces...

diagnostics.json

JSON

Structure imbriquée : un ou plusieurs codes par séjour.

```
[ { "stay_id": "S00000123", "diagnostics": [ {  
  "code_cim10": "...", "type": "principal" }, {  
  "code_cim10": "...", "type": "associe" } ] } ]
```

monitoring.parquet

Parquet

Flux volumineux
(constantes au chevet)

COLONNE	TYPE
stay_id	texte
ts	horodatage
heart_rate	entier (bpm)
spo2	entier (%)
temp_c	décimal (°C)

referentiels/ – services.csv · cim10.csv

CSV

Nomenclatures, déposées le premier jour

services code → libellé du service · cim10 code diagnostic → libellé

⚠ Les données brutes reflètent la vraie vie

Elles ne sont pas forcément propres ni cohérentes. Une partie du travail consiste précisément à **détecter et traiter** les problèmes de qualité (voir ci-dessous).

Contrôles qualité attendus (indicatifs)

Vous n'êtes pas médecins : on vous donne les **règles métier** et les **catégories de contrôles**. À vous de les implémenter (couche silver), de tracer ce que vous écarterez, et d'en repérer d'autres en explorant.

DOMAINE	CONTRÔLE ATTENDU	RÈGLE / BORNE
patients	Doublons (retour quotidien du même patient)	Dédupliquer, garder la version la plus récente
sejours	Cohérence temporelle	Écarter si discharge_ts < admission_ts
sejours	Séjour en cours	discharge_ts vide = légitime , pas une erreur
monitoring	Valeurs hors plage physiologique	FC 20–250 bpm · SpO2 50–100 % · temp 30–45 °C
tous	Valeurs manquantes / formats	Dates valides, sexe normalisé (M/F)...

Ce qu'on évalue

À vous de **détecter** les lignes concernées. Le traitement attendu est simple : on les **écarte** (et on **déduplique** les patients). Seule exception : un séjour **sans date de sortie** n'est pas une anomalie (patient encore hospitalisé), on le **conserve**.

4 Le besoin métier

Pilotage hospitalier

- **Durée Moyenne de Séjour (DMS)** par service
- **Activité des urgences** : passages par jour
- **Taux de réadmission à 30 jours** (qualité des soins)
- **Surveillance des constantes** : relevés en alerte / jour
- Toute autre vue d'activité pertinente

Recherche clinique

- **Prévalence par pathologie** : taille des cohortes par diagnostic
- **Description de cohorte** : distribution par âge et sexe

Les indicateurs doivent être **fiables, cohérents** avec les sources, et vous devez pouvoir **justifier chaque chiffre**.

5 Contraintes

CONTRAINTE	CE QU'ON ATTEND
Incrémental	Ingérer chaque jour les nouveaux fichiers, sans retraiter ni dupliquer les anciens.
Volume	Le monitoring est bien plus gros que le reste : l'architecture doit tenir la charge.
RGPD — pseudonymisation	Les patients arrivent avec leur identité en clair (nom, NIR...). Aucune donnée identifiante ne doit entrer dans l'entrepôt : pseudonymisez dès l'entrée du lake , avec un pseudonyme stable (pour préserver les jointures).
RGPD — minimisation	Ne conservez que ce qui est utile à l'usage.
RGPD — cloisonnement	Pilotage et recherche ne voient pas les mêmes données → droits d'accès distincts .
RGPD — petits effectifs	En recherche, ne diffusez pas les cohortes de moins de 5 patients .
Traçabilité	Savoir d'où vient chaque donnée et quand elle a été traitée.

6 Architecture conseillée

Vous êtes libres de vos choix, mais voici la trajectoire attendue — que vous devrez **justifier** dans votre dossier. Le patron « **médaille** » :



Stack conseillé (tourne sur un laptop)

- **Entrepôt** : **ClickHouse** en local (Docker) — warehouse colonne, UI SQL intégrée (:8123/play)
- **Ingestion / orchestration** : **Python** — recopier les fichiers puis **envoyer le SQL**
- **Restitution** : **Metabase** (Docker) — dashboards sans code

Rôle des couches

COUCHE	RÔLE
Lake	copie brute, telle quelle
Bronze	tables typées, peu transformées
Silver	nettoyé, cohérent, enrichi
Gold	indicateurs par usage

Principe à respecter

La **transformation** (bronze→silver→gold) s'exécute **dans ClickHouse** (en SQL). Python **pilote** (copie + envoi des requêtes). **Ne sortez pas** les données du moteur pour les transformer en mémoire (pandas) : ça ne passe pas à l'échelle — c'est l'**anti-pattern** classique du Big Data.

7 Livrables attendus

Partie 1 — Interface d'analyse

- **Un dossier** : besoin, sources, **schéma d'architecture** justifié, traitements, indicateurs, visualisations, **limites & recommandations**.
- **Une interface** : ≥ 2 dashboards (pilotage + recherche) avec démonstration du **cloisonnement des droits**.

Partie 2 — Automatisation

- **L'automatisation** du pipeline (collecte + transformation planifiées), avec **gestion des erreurs**, **journalisation**, **traçabilité**.
- **Une documentation** d'utilisation et de maintenance (lancement, reprise sur incident).

★ Bonus fortement valorisé — anonymisation automatisée à l'entrée du lake

Un process qui, à l'ingestion, **pseudonymise** l'identifiant patient (hachage **déterministe avec sel** → stable et non réversible), **généralise** la date de naissance (→ année) et **supprime** les identifiants directs (nom, prénom, NIR). Aucune donnée identifiante ne doit jamais atteindre l'entrepôt.

8 Critères d'évaluation (indicatif)

CRITÈRE	CE QU'ON REGARDE
Analyse du besoin	Vous avez compris ce que veut l'hôpital
Architecture	Choix cohérents et justifiés , schéma clair
Qualité des traitements	Anomalies détectées et traitées, données fiables
Fiabilité des indicateurs	Chiffres justes, cohérents, reproductibles
Restitution	Dashboards lisibles, adaptés aux deux publics
Automatisation	Rejouable, incrémentale, robuste aux erreurs
RGPD / gouvernance	Pseudonymisation, cloisonnement, petits effectifs, traçabilité
Documentation	Claire, suffisante pour reprendre le projet

Commencez par **explorer les fichiers** pour comprendre ce que vous avez entre les mains avant de coder quoi que ce soit. — Bon courage.